

Tema 1: Depuración, Análisis y Visualización de Datos

1. Depuración y tratamiento de datos

1.1. Fundamentación de la depuración como modelo de la realidad

La depuración de datos **no es un mero proceso técnico de limpieza**, sino una **primera fase estratégica** esencial para el análisis, y debe ir por tanto **en total connivencia con sus objetivos y propuestas**. Esto no se debe sólo a que la precisión en la limpieza sea esencial para obtener resultados robustos, sino también a que la **limpieza a menudo conlleva tomar decisiones que dan forma a los cimientos** sobre los que se construye el estudio.

↳ y determinan el resultado

Por ejemplo, si uno trabaja con la Muestra Continua de Vidas Laborales y quiere medir el periodo en el que una persona ha estado en desempleo, **podrá utilizar los periodos en episodio de desempleo registrado o los periodos en los que no ha estado en un episodio de empleo**. La diferencia entre estas dos métricas es notable, pero ninguna es más adecuada que la otra hasta que se tiene en cuenta el objetivo del análisis y el uso que se le va a dar a la misma.

La depuración de los datos puede conllevar múltiples procesos:

a) Adecuación del formato de la base de datos

La manera en la que los diversos formatos guardan la información (**extensión**) tiene consecuencias en el tamaño y la facilidad de lectura de los mismos. Algunos formatos como **.txt o .xlsx pueden ser muy cómodos para bases de datos pequeñas, pero tremendamente costosos en cuanto a memoria para bases más grandes**. Por tanto, es importante adecuar el formato de la base de datos dependiendo de su tamaño, forma y el uso que se le vaya a dar. Por ejemplo, **.parquet es un tipo de archivo comprimido que reduce el espacio ocupado en el ordenador y de rápida lectura para la mayoría de los softwares**.

→ Codificar variables para evitar strings

Otro aspecto relevante del formato de los datos es su **codificación**. En general, se tiene a **evitar caracteres no comunes como tildes o la letra ñ**, así como los espacios en los nombres de las variables.

↳ En caso de usarlos usar una codificación estilo UTF-8

Transformar los datos vírgenes a una extensión y codificación que permiten la consistencia en la lectura de los datos de las diferentes personas que vayan a tratarlos es esencial para el análisis.

b) Eliminación de información superflua o ruidosa

Uno de los pasos más importantes en la limpieza de datos es la eliminación de la **información no relevante o ruidosa** para el análisis. Seleccionar **sólo las columnas que se van a utilizar o eliminar aquellas filas que no aportan información necesaria** para el estudio **permite facilitar la legibilidad de los datos y mejorar la eficiencia** del uso de recursos por parte del programa utilizado.

↳ Mayoría de softwares permiten hacerlo desde la carga

La eliminación de filas puede ser más delicada, pues suele significar la eliminación de observaciones y por tanto debe estar justificada. Para las variables numéricas esto puede significar establecer criterios de igualdad o desigualdad (por ejemplo, mantener sólo las observaciones de individuos en edad de trabajar: $x \geq 16$ & $x \leq 65$); y para variables categóricas criterios de contenido (como eliminar las observaciones que sean igual a, contengan, empiecen por, o acaben en un string determinado).

Esta tarea incluye también la decisión de elegir qué hacer con las observaciones vacías o con valores atípicos. Algunas de las maneras más populares de tratar con este tipo de dato es su eliminación o su permutación por la media, la moda, la mediana o la estimación de un modelo.

c) Adición de información

Se refiere a la unión de dos bases de datos diferentes a través de una o varias columnas en común. Por ejemplo, una base de datos A con una lista de individuos y sus edades puede unirse a una base de datos B con la lista de individuos y su renta. En caso de que la lista de individuos no coincida exactamente en ambas bases de datos, el analista debe elegir si quedarse con los individuos de A y añadir la información (mientras exista) de B; mantener los individuos de B y añadir la información (mientras exista) de A; mantener los individuos que figuren solamente en ambas listas; mantener a los individuos que estén en alguna de ambas listas, aunque eso genere celdas vacías en ambas variables.

d) Forma de los datos

Los datos pueden encontrarse en formato largo o ancho. Una base de datos en formato ancho, por ejemplo, puede incluir una fila por individuo y una columna por cada año de renta. Esta misma base de datos en formato largo contendría tantas filas como años de renta presenta el individuo, y tan sólo dos columnas indicando el año al que se refiere el dato y su valor.

e) Creación de variables

La creación de variables puede deberse a:

- **Modificación de una variable ya existente:** como centrar variables numéricas o eliminar parte del texto de una variable string.
- **Creación de una variable nueva a partir de otras:** como calcular la renta total de un individuo sumando las variables que refieren a su renta laboral y su renta del capital
- **Modificación del nombre de una variable:** no transforma los valores de la variable en sí, sólo su nombre

f) Agrupaciones

Otro de los principales recursos utilizados a la hora de limpiar datos son las agrupaciones, lo que puede cambiar la estructura de la base de datos. Por ejemplo, en una base de datos con registros individuales de renta, uno puede calcular la media de renta de la región, obteniendo una nueva base de datos con

una fila por región. Por otro lado, si uno no quiere perder la granularidad de la base en cuestión, podría simplemente añadir una columna con el valor de esta renta media regional, aunque cada dato estaría repetido tantas veces como individuos hubiera en cada región.

2. Análisis exploratorio y estadístico de datos

El análisis exploratorio de las variables permite establecer un primer contacto con la información disponible en la base de datos. La exploración da lugar a conocer si existen observaciones vacías o atípicas, la clase de valor, la escala en la que se mueve, la unidad de medida, y la distribución.

2.1. Clasificación y naturaleza de las variables

La metodología exige clasificar los datos según su escala de medición. Las variables numéricas (cuantitativas) pueden ser continuas o discretas, mientras que las categóricas (cualitativas) describen atributos o etiquetas que no admiten operaciones aritméticas directas sin transformación previa, aunque pueden estar ordenadas, como los niveles educativos.

2.2. Medidas de localización y posición

Estas medidas sintetizan la distribución de los datos en puntos estratégicos:


- 1. Media aritmética:** Medida de tendencia central por excelencia para variables numéricas.
- 2. Mediana:** Valor central que divide la distribución en dos segmentos de igual tamaño (50% superior e inferior).
- 3. Moda:** Valor de máxima frecuencia, esencial para el análisis de datos categóricos.
- 4. Cuartiles y percentiles:** Localizadores que dividen el conjunto de datos en tramos proporcionales para identificar la posición relativa de una observación.

2.3. Medidas de dispersión

La variabilidad se mide a través de la dispersión respecto al centro. Sin embargo, para comprender la naturaleza de la distribución, es crucial analizar variables de dispersión como el sesgo, la curtosis, la varianza o el rango intercuartílico:

Sesgo: mide si la distribución está inclinada hacia un lado. Puede ser positiva si la distribución está alargada hacia la derecha (valores extremos altos), o negativa en el caso contrario.

Curtosis: mide cuán concentrados están los valores con respecto a la media. Una alta curtosis implica una alta concentración alrededor de la media, lo que se traduce en una distribución con un pico alto y colas menos pronunciadas. Una baja curtosis, implica una distribución más plana, con colas pronunciadas y menos pico.



BIVARIABLE → para correlación → puntos
→ para heterog. → Matriz covarianza
→ Cualquier cosa anterior pero desagregando
Ej: histograma superpuesto con transparencia alta

Varianza: mide la dispersión media de los datos con respecto al promedio. Se expresa en desviaciones cuadradas, por lo que a menudo se muestra en su lugar la desviación típica, que es la raíz cuadrada de la varianza.

Rango intercuartílico: diferencia entre el percentil 75 y el 25. Es una medida más robusta a valores extremos.

2.4. Tablas de frecuencias, y gráficos de densidad/histogramas

Las **tablas de frecuencias** se suelen utilizar con **variables que tienen pocos valores posibles o que son discretas**. Aportan información de con cuánta frecuencia (absoluta y/o relativa) se puede encontrar un valor en la base de datos.

Cuando el dato es **continuo**, suele utilizarse el **gráfico de densidad o el histograma**, que muestran gráficamente la frecuencia del dato.

3. Visualización de datos

Principios de representación y función interpretativa

La visualización estadística no es una un mero adorno estético, sino una **herramienta de reducción del caos del dato bruto en estructuras** que el investigador puede procesar para extraer conclusiones significativas. → Capacidad de síntesis

3.1. Tabulación

Las **tablas de frecuencia y de frecuencia relativa acumulada son el primer peldaño** del análisis descriptivo, permitiendo observar la distribución de probabilidad empírica de la muestra. → si discreto

3.2. Catálogo de Gráficos Estadísticos

- **Histogramas y gráficos de densidad:** Cruciales para diagnosticar la simetría y la forma de la distribución.
- **Box-plots (Diagramas de caja):** Herramienta por excelencia para visualizar la dispersión, los cuartiles y aplicar visualmente la regla del 1.5 IQR para identificar valores atípicos.
- **Diagramas de Dispersión:** Esenciales para explorar la correlación y las relaciones funcionales entre variables numéricas.
- **Gráficos de Barras y Líneas:** Utilizados para comparaciones categóricas y el análisis de tendencias en series temporales.

Existen muchos otros tipos de visualización de datos, como los gráficos de **tarta**, los **de flujos**, los **mapas de calor** o los **mapas geográficos**.

3.3. Interfaces para la Toma de Decisiones

Existen también los gráficos/tablas **interactivas** que permiten manipular el dato a la vez que se visualiza, permitiendo al analista cambiar el ángulo desde el cual se acerca al dato, o **visualizar muchos a la vez de manera cómoda**.

→ como dashboards o shiny

Ej: → Selección de variables, filtros, etc.
→ Progresión histórica del dato

