

Tema 3. Modelos de regresión general lineales y no lineales. Inferencia causal, panorámica de los métodos experimentales y cuasi-experimentales.

1. Modelos de regresión general lineales y no lineales.

1.1. Modelo de regresión general lineal

Los modelos lineales engloban un conjunto de técnicas estadísticas que intentan explicar una variable dependiente continua en función de una o más variables explicativas, asumiendo relación de tipo lineal entre ellas. Bajo este modelo se incluyen diferentes análisis: test t-Student, F-test, el Análisis de la Varianza y el Análisis de la Covarianza (todo estimados a través de pruebas de contraste de hipótesis univariantes independientes), y la regresión lineal (simple y múltiple).

Los modelos de regresión lineal, de forma más específica, son uno de los principales instrumentos empíricos de los que dispone la evaluación de políticas. Los conceptos de regresión lineal son de carácter fundamental, y sirven de base para herramientas más elaboradas (tanto para datos de corte transversal como para datos de panel).

1.2. Regresión lineal e inferencia causal en EPP


La regresión lineal es ampliamente utilizada para la inferencia causal en entornos experimentales, aunque también es posible encontrarla en entornos no experimentales.

Pongamos que queremos estimar el efecto de los años de educación en la renta y poseemos datos administrativos. Si realizamos una regresión lineal simple, no podríamos entender de forma causal el coeficiente de los años de educación. Esto se debe a que, ya que los años de educación están correlaciones con otras variables como la edad o el entorno socioeconómico del sujeto, el coeficiente estaría capturando también los efectos de estas variables en la renta, y se produciría sesgo de omisión de variables. Sin embargo, sí podríamos afirmar con tranquilidad que “un año más de educación se correlaciona con beta renta más”. Si imaginamos un mundo en el que sólo esas otras dos variables afectan a la renta a través de la variable de años de educación, incluirlas significaría que “controlamos” por ellas, y por tanto podríamos aislar el efecto de los años de educación en la renta. Esto se llama CIA (Conditional Independency Assumption). Sin embargo, este es un supuesto muy poco fiable (normalmente hay más variables que pueden estar afectando y que no podemos incluir en la regresión) y además improbable. Por tanto, la regresión lineal es poco fiable como herramienta causal en entornos no experimentales.

En entornos experimentales, donde el tratamiento es aleatorizado e incluso a veces aleatorizado con estratificación, el cumplimiento de la CIA no supone ningún problema, puesto que en principio ninguna variable se puede correlacionar con la variable de tratamiento si esta es aleatoria y la muestra lo suficientemente grande. Por tanto, la regresión lineal se utiliza con asiduidad en entornos experimentales.

1.3. Estimación básica del modelo. MCO

La estimación de un modelo lineal por mínimos cuadrados ordinarios (MCO) consiste en un método estadístico que calcula la mejor recta de ajuste para un conjunto de datos, para



la estimación de regresión lineal (no es el único, también puede hacerse por MV y MGM). La estimación por MCO **busca la recta óptima** (o plano, en casos de múltiples variables independientes) **que minimiza la suma del cuadrado de los residuos** (diferencia entre los valores observados y los valores predichos por el modelo).

Este método es ampliamente utilizado debido a sus buenas propiedades matemáticas y estadísticas. Proporciona estimaciones no sesgadas de los parámetros del modelo bajo ciertas condiciones y **permite la evaluación de la significancia estadística de las relaciones entre las variables**, así como del modelo. Además, se calcula el Coeficiente de Determinación R^2 , que es la expresión, entre 0 y 1, de la variabilidad de la variable y que es explicada por la (o las) variable(s) x .

Sin embargo, es importante tener en cuenta que el método de mínimos cuadrados ordinarios **puede no ser apropiado si los supuestos subyacentes no se cumplen**.

Para que la estimación por mínimos cuadrados ordinarios (MCO) sea válida y produzca resultados precisos (es decir, sea consistente, insesgada y eficiente), es importante que se cumplan varias condiciones clave (supuestos del modelo):

1. Linealidad: La relación entre la variable dependiente y las variables independientes debe ser **aproximadamente lineal**. Esto significa que los cambios en la variable dependiente deben estar relacionados con cambios proporcionales en las variables independientes. Se puede testar con análisis de los gráficos de dispersión y los gráficos de residuos. **No obstante, también existen maneras de incluir no linealidad como hacer transformaciones logarítmicas o cuadráticas a las variables.**

2. Independencia de errores: Los errores (las diferencias entre los valores observados y los valores predichos) **deben ser independientes entre sí**. Esto significa que **el error asociado con una observación no debe estar relacionado con el error de otra observación**. Se puede testar con el test de Durbin-Watson. *↳ por ejemplo ind. de mismas empresas o en series temporales*

3. Homocedasticidad: La **varianza de los errores debe ser constante en todos los niveles de las variables independientes**. En otras palabras, la dispersión de los errores alrededor de la línea de regresión no debe cambiar a medida que cambian los valores de las variables independientes. Prueba de Breusch-Pagan o **White**.

4. Normalidad de los errores: Los errores deben seguir una distribución normal. **Para cada valor de la variable independiente** (o combinación de valores de las variables independientes), **los residuos se han de distribuir normalmente con media cero**. Prueba de normalidad de **Shapiro-Wilk** (para $N < 50$) o **Kolmogorov-Smirnov** (recomendable para $N > 50$).

5. No multicolinealidad: Si hay múltiples variables independientes en el modelo, estas **no deben estar altamente correlacionadas entre sí**. La multicolinealidad puede hacer que las estimaciones de los coeficientes sean inestables y difíciles de interpretar. Se puede testar a través del **Factor de Inflación de la Varianza** (VIF por sus siglas en inglés)

Si las condiciones de MCO no se cumplen, las estimaciones por mínimos cuadrados ordinarios pueden ser sesgadas y/o ineficientes. En tales casos, pueden ser necesarios métodos alternativos de estimación, que detallamos en el siguiente apartado.

1.4. Método de los momentos

El método de momentos consiste en estimar parámetros utilizando propiedades que sabemos que deben cumplirse en la población. La idea es sencilla: si sabemos que en la población una cierta expresión tiene esperanza cero, en la muestra podemos imponer que su promedio sea aproximadamente cero y elegir los parámetros del modelo de manera que esa condición se cumpla. En esencia, sustituimos momentos poblacionales (valores esperados) por sus equivalentes muestrales y resolvemos las ecuaciones resultantes.

En el contexto de una regresión lineal, el supuesto clave es que las variables explicativas son exógenas, lo que implica que no están correlacionadas con el término de error. Esto puede escribirse como $E[Xu]=0$. Esta es una condición de momento: cada regresor debe tener covarianza cero con el error. Como el error no es observable, lo sustituimos por el residuo $u_i = y_i - X_i\beta$. El método de momentos consiste entonces en escoger β de forma que las covarianzas muestrales entre los regresores y los residuos sean cero. Cuando resolvemos estas ecuaciones obtenemos exactamente el estimador de Ordinary Least Squares. Por tanto, OLS puede entenderse como un caso particular del método de momentos en el que usamos como instrumentos las propias variables explicativas.

El Generalized Method of Moments amplía esta idea permitiendo utilizar más condiciones de momento que parámetros. En lugar de requerir únicamente que los regresores no estén correlacionados con el error, podemos tener un conjunto más amplio de variables z (instrumentos) que también sabemos que son exógenas, lo que genera condiciones de momento del tipo $E[z_i u_i] = 0$. Si el número de instrumentos coincide con el número de parámetros, el sistema puede resolverse exactamente, igual que en OLS. Pero cuando tenemos más instrumentos que parámetros —lo que se denomina sobreidentificación— no es posible satisfacer todas las condiciones simultáneamente.

Esto es precisamente lo que ocurre en modelos de Instrumental Variables o en Two-Stage Least Squares cuando existen más instrumentos que regresores endógenos. En ese caso tenemos más ecuaciones de momento que parámetros que estimar. El método generalizado de momentos resuelve este problema eligiendo los parámetros que hacen que esas condiciones de momento estén lo más cerca posible de cumplirse, minimizando una combinación cuadrática de los errores de momento.

Una ventaja importante de GMM es que funciona bajo supuestos más flexibles que OLS. Mientras que OLS suele derivarse bajo hipótesis como homocedasticidad o ausencia de autocorrelación para obtener estimadores eficientes y varianzas correctas, GMM permite construir estimadores consistentes y eficientes incluso cuando estas condiciones no se cumplen, siempre que las condiciones de momento sean válidas. Además, mediante la elección de una matriz de ponderación adecuada, GMM puede adaptarse a la presencia de heterocedasticidad o correlación serial en los errores. Por esta razón, GMM suele considerarse un marco más general y robusto para la estimación econométrica.

Desde esta perspectiva, OLS aparece como un caso especial de GMM en el que los instrumentos son exactamente los regresores y el número de condiciones de momento coincide con el número de parámetros.

1.5. Modelo Tobit

Por su importancia, señalamos aquí un modelo lineal que, bajo determinadas circunstancias y a pesar de existir una relación lineal entre las variables, MCO puede no ser adecuado. Se trata del **Modelo Tobit**, siendo la aplicación del modelo de regresión lineal a VD limitadas, que utiliza el método de MV para su estimación. El método supone la existencia de una variable dependiente latente, Y^* , no observable, que satisface los supuestos del modelo lineal clásico, y que expresa la respuesta observada Y , y que puede ser predicha como combinación lineal de un vector de variables independientes X . Encontramos dos modelos esenciales:

- **Para datos Censurados.** Se considera que los datos están censurados cuando existe un determinado límite en la variable respuesta (superior, inferior o ambos) a partir del cual a todas las observaciones se les asigna un mismo valor, de tal manera que, asumiendo censura inferior (es similar para superior) $y=y^*$ cuando $y^*>\tau$, e $y=\tau$ cuando $y^*\leq\tau$, con distribución continua a lo largo de los valores positivos, siendo τ el límite de la censura.

La característica fundamental de un escenario censurado es que hay una población subyacente en la que sí existen observaciones fuera de los límites de censura, sin embargo, debido a la incapacidad para detectarlas/seleccionarlas en el muestreo, la población observada parece no contenerlas (por ejemplo, cuando se establece en una encuesta un límite superior de rentas: las observaciones por encima de esa renta tendrán el valor del límite máximo).

- **Para datos Truncados.** Las situaciones con datos truncados aparecen cuando en una población a partir de un determinado límite no existen observaciones. La diferencia fundamental respecto a los datos censurados es que, en estos últimos, las observaciones sí existen en la población latente pero no se captan en el muestreo.

2. Modelos de regresión ante alteraciones de los supuestos de MCO.

Como se ha señalado previamente, cuando no se cumple alguna de los supuestos de MCO enumerados previamente, contamos con otros métodos de regresión que son de aplicación, que en la práctica estiman modelos con relaciones “arbitrarias” entre la variable dependiente y el conjunto de variables independientes, tales como modelos con variables dependientes no continuas o con distribución no normal.

Los principales modelos son:

A. Modelos aditivos. Permiten la estimación de modelos con relaciones no lineales entre la VD y las VI. El modelo establece que la relación entre Y y X viene dada por una función de suavizado f que sustituye a los coeficientes β . De este modo, en lugar de tener

una relación constante entre X e Y, la función f permite modelar una relación cambiante. Los tipos de suavizado que pueden realizarse son: **LOESS** (regresión lineal ponderada en una ventana alrededor del valor objetivo), y los diferentes modelos de regresión **splines**: simple, cuadrática, cúbica, y suavizante (o penalizada).

El supuesto exigido es el de errores con distribución N, si bien podemos utilizar los **modelos aditivos generalizados (GAM)** en el caso de no cumplirse ese supuesto.

B. Modelos lineales generalizados. Se trata de una **generalización flexible** de la regresión lineal ordinaria que permite variables de respuesta con modelos de distribución de errores distintos de una distribución normal, y que nos ofrece una serie de modelos de regresión muy utilizados en la investigación cuantitativa empírica. De esta manera, estos modelos permiten utilizar distribuciones no normales para los errores (o varianzas no constantes, como puede ser el caso de los modelos de conteo).

Un modelo lineal generalizado tiene tres componentes básicos: componente aleatoria: identifica la variable respuesta y , y su distribución de probabilidad; componente sistemática: especifica las variables explicativas (independientes o predictoras) utilizadas en la función predictora lineal; y una Función de Enlace, que es una función del valor esperado de Y, $E(Y)$, como una combinación lineal de las variables predictoras.

En función de la naturaleza de la VD, podemos clasificar los MLG en:

1. **Regresión Logística.** Muy utilizada para variables dependientes binarias, y por tanto para estimar la probabilidad de que un suceso ocurra. En este caso no se utilizan regresiones lineales en parte porque esto podría dar lugar a predicciones de probabilidad inferior a 0 o superior a 1, lo que no es real. Por tanto, se realiza una regresión por MLE del logaritmo de odds ratio (es decir, de $p/(1-p)$). Como interpretar los coeficientes como cambios en log-odds es poco intuitivo, se suelen estimar Average Marginal Effects que muestran el cambio promedio en puntos porcentuales de la variable dependiente.
2. **Regresión probit.** Al igual que la regresión logística, se utiliza para modelar variables dependientes binarias y estimar la probabilidad de que ocurra un evento. En este caso se supone que existe una variable latente continua cuya relación con las variables explicativas es lineal, y el evento ocurre cuando esa variable supera cierto umbral. La probabilidad del evento se modela utilizando la función de distribución acumulada de una distribución normal estándar, lo que garantiza que las probabilidades estimadas estén siempre entre 0 y 1. Los parámetros del modelo se estiman mediante Maximum Likelihood Estimation y, al igual que en el modelo logit, la interpretación suele realizarse mediante Average Marginal Effects, que indican el cambio en la probabilidad del evento ante variaciones en las variables explicativas.
3. **Regresión logística multinomial.** Generaliza el método de regresión logística para modelos con variable dependiente de tipo nominal con más de dos categorías (politómica). Modela así las probabilidades relativas de cada categoría de la variable de respuesta en relación con una categoría de referencia, a partir de un conjunto de predictores, para estimar los efectos de las variables independientes en las probabilidades de pertenecer a cada categoría de la variable dependiente.

4. **Regresión probit multinomial.** Generalización de la regresión probit para VD nominal politómica.
5. **Modelos logit y probit ordenados.** Son extensiones de la regresión logística y probit para variables de respuesta categóricas ordenadas. Se utilizan cuando la variable de respuesta tiene más de dos categorías ordenadas, pero no equidistantes (por ejemplo, el nivel de formación alcanzado, o el status socioeconómico, o el nivel de salud autorreportado). En un modelo logit o probit ordenado, se modela la probabilidad de que la variable de respuesta caiga en o por debajo/encima de un cierto punto en la escala ordinal. Se pueden estimar los parámetros del modelo utilizando métodos de MV o mediante técnicas de estimación bayesiana.
6. **Regresión de Poisson.** Útil para datos de conteo.

Al aplicar este tipo de modelos a datos reales, en algunos casos, se dan fenómenos tales como:

- Sobredispersión: Una peculiaridad de la distribución de Poisson es que su media es igual a su varianza ($\lambda = \mu = \sigma^2$). Sin embargo, en ciertos conjuntos de datos se observa una varianza superior a la esperada. El fenómeno se conoce como sobredispersión (overdispersion) e indica que el modelo no es adecuado. Un motivo frecuente es la omisión de alguna variable relevante. En estos casos puede ser útil recurrir a la **distribución binomial negativa**.
 - Exceso de ceros: Otro fenómeno que aparece en la práctica es el del exceso de ceros. Esto ocurre, por ejemplo, al tratar de modelar el valor de las ayudas públicas para cada uno de los integrantes de un grupo de personas: puede que algunos de ellos (o muchos), simplemente, no reciban ayudas. Para desarrollar modelos estadísticos que modelen adecuadamente el exceso de ceros es importante entender los mecanismos que originan a los ceros. En este sentido, se debe determinar si se trata de ceros estructurales (presentes de forma estructural) o muestrales (cero observado en el momento de la muestra, pero que puede no existir en otro momento). Uno de los enfoques de modelación más utilizados consiste en ajustar un modelo lineal generalizado en el cual la variable respuesta Y se modela con alguna distribución discreta que pertenece a la familia exponencial. El modelo más utilizado en este caso es el **zero-inflated Poisson regression**, que tiene dos partes, un modelo de recuento de Poisson y el modelo logit para predecir el exceso de ceros.
7. **Modelos de duración.** Se utilizan cuando la variable dependiente es el tiempo hasta que ocurre un evento. Ejemplos habituales en economía son el tiempo hasta encontrar empleo, la duración de un contrato laboral, el tiempo hasta que una empresa quiebra o la duración de un episodio de desempleo. A diferencia de una regresión lineal estándar, los modelos de duración están diseñados para tratar dos características típicas de este tipo de datos. Primero, el tiempo de duración es siempre no negativo y suele tener una distribución muy asimétrica. Segundo, es frecuente la presencia de censura, es decir, observaciones para las que sabemos que el evento no ha ocurrido hasta cierto momento, pero no conocemos el momento exacto en que ocurrirá (por

ejemplo, individuos que siguen desempleados al final del periodo de observación). Los modelos de duración permiten incorporar correctamente este tipo de información incompleta.

En lugar de modelar directamente el tiempo de duración, estos modelos suelen centrarse en la **Hazard Rate**, que mide la probabilidad instantánea de que el evento ocurra en el momento t , condicionada a que no haya ocurrido antes. Intuitivamente, la hazard responde a la pregunta: *si el individuo ha “sobrevivido” hasta el momento t , ¿cuál es el riesgo de que el evento ocurra ahora?* A partir de la hazard se pueden derivar otras funciones fundamentales del análisis de duración, como la función de supervivencia, que indica la probabilidad de que el evento no haya ocurrido todavía en un momento determinado.

Existen diferentes tipos de modelos de duración dependiendo de cómo se especifique la relación entre el tiempo y las variables explicativas. Algunos modelos suponen una forma paramétrica concreta para la distribución de las duraciones (por ejemplo, exponencial o Weibull), mientras que otros son más flexibles. Uno de los modelos más utilizados es el **Cox Proportional Hazards Model**, que especifica que la hazard de un individuo es el producto de una hazard base que depende del tiempo y un factor exponencial que depende de las características observadas del individuo. Esto permite estimar el efecto de las variables explicativas sobre el riesgo de que ocurra el evento sin necesidad de especificar completamente la forma de la distribución del tiempo de duración.

Los parámetros de los modelos de duración suelen estimarse mediante **Maximum Likelihood Estimation**. La interpretación de los coeficientes depende del modelo concreto, pero en muchos casos se interpretan como **multiplicadores del riesgo** (hazard ratios), que indican cómo cambian las probabilidades instantáneas de que ocurra el evento cuando cambia una variable explicativa. Por ejemplo, un hazard ratio mayor que uno indica que la variable aumenta el riesgo de que el evento ocurra antes, mientras que un valor menor que uno indica que reduce ese riesgo y por tanto tiende a alargar la duración esperada.

8. **Regresiones con datos de panel**. Se utilizan cuando observamos a las mismas unidades (individuos, empresas, regiones, etc.) en varios periodos de tiempo. Esto permite aprovechar tanto la variación entre unidades como la variación dentro de cada unidad a lo largo del tiempo. Un modelo básico puede escribirse como:

$$Y_{it} = \beta X_{it} + \alpha_i + \varepsilon_{it}$$

donde i identifica la unidad y t el periodo. El término α_i recoge características no observadas de cada unidad que permanecen constantes en el tiempo (por ejemplo, habilidades, cultura empresarial o características institucionales).

En muchos casos se utilizan modelos de **Fixed Effects Model**, que eliminan esas características constantes mediante transformaciones que utilizan únicamente la variación dentro de cada unidad a lo largo del tiempo. Por ello, en estos modelos solo tiene sentido incluir variables explicativas que varían en el tiempo, ya que las variables constantes quedan absorbidas por los efectos fijos y no pueden identificarse. Alternativamente, los modelos de **Random Effects Model** tratan esa heterogeneidad

individual como un componente aleatorio del error, aunque requieren supuestos más restrictivos.

La interpretación de los coeficientes en modelos de panel con efectos fijos se basa en cambios dentro de la misma unidad a lo largo del tiempo. Es decir, el coeficiente β mide cómo cambia la variable dependiente cuando cambia la variable explicativa dentro de una misma unidad, manteniendo constantes las características inobservadas de esa unidad. Estos modelos suelen estimarse mediante **Ordinary Least Squares** tras aplicar la transformación correspondiente.

C. **Modelos lineales mixtos.** Permiten modelar la varianza en lugar de asumir que es constante, así como la presencia de observaciones correlacionadas (ausencia de independencia), por ejemplo, observaciones de estudiantes agrupados en diferentes aulas. Amplían el modelo lineal general de manera que los datos puedan presentar de esta manera variabilidad correlacionada y no constante. El modelo lineal mixto proporciona, por tanto, la flexibilidad necesaria para modelar no sólo las medias sino también las varianzas y covarianzas de los datos. Combinan efectos fijos y aleatorios. En el caso de que no se cumpla la normalidad, podemos utilizar los **modelos lineales mixtos generalizados**.

3. Inferencia causal, panorámica de los métodos experimentales y cuasi-experimentales.

La inferencia causal es el proceso de identificar y comprender las relaciones de causa y efecto entre variables en un sistema (en este caso, de una determinada PP), esto es, entre una variable causante de un determinado resultado en una variable dependiente. La evaluación del efecto causal es importante en la investigación de impacto en ciencias sociales, ya que permite determinar si una intervención tuvo un efecto significativo y, en caso afirmativo, cuál fue su magnitud. Los métodos experimentales y cuasi-experimentales son los dos enfoques principales utilizados para realizar inferencia causal en ciencias sociales y otras disciplinas.

3.1. Métodos Experimentales:

Cuando se quiere analizar el impacto de, por ejemplo, una política pública, el **objetivo** es estimar el efecto de esta misma formulado como $ATE = E[Y_{t+1}(1)] - E[Y_{t+1}(0)]$. Es decir, la diferencia en la variable de interés de un grupo afectado por una política y el mismo grupo si no hubiera sido afectado. Sin embargo, esto no es posible.

Los **métodos experimentales**, y en especial el experimento controlado aleatorizado (ECA en español y RCT en inglés), tiene como objetivo simular esto mediante la aleatorización del tratamiento. Si aleatorizamos el tratamiento dentro de un grupo, y más todavía si se hace con estratificación y con una muestra lo suficientemente grande, podemos decir con cierta confianza que, de media, estos grupos son similares, puesto que no ha habido ninguna razón arbitraria para elegir quién es tratado y quién no. De esta manera,

podríamos suponer que la media de la variable de interés del grupo no tratado en el momento $t+1$ es semejante a la del grupo de tratamiento si no hubiera sido tratado. Por tanto, con una regresión lineal común o comparación de medias podríamos estimar los efectos de dicho tratamiento. También encontramos a veces experimentos naturales, como eventos climatológicos.

No obstante, deben cumplimentarse ciertas condiciones:

Validez interna

- Muestra lo suficientemente grande para estar seguros de que ambos grupos son similares. Es especialmente importante estratificar por observables cuando la muestra no es tan grande.
- Aleatorización en el tratamiento, sea con estratificación o no.
- No efecto contaminación. El tratamiento no puede afectar de ninguna manera en el grupo de control. Por ejemplo si uno dota de herramientas digitales a unos alumnos de una clase y a otros no, los no tratados podrían beneficiarse de las herramientas digitales de sus compañeros tratados.
- No attrition. Si algunos de los tratados abandonan el experimento, los resultados pueden estar sesgados. Por ejemplo si uno prueba una medicina y un 10% de la muestra no completa el tratamiento, podría ser porque los tratados se han curado con rapidez gracias al tratamiento o porque la medicina no les ha servido y por tanto la han abandonado. No contar con sus observaciones sesga los resultados, y en caso de encontrar attrition debe estudiarse si esta ha sido aleatoria y por tanto no afecta a los resultados o si entonces debiera estimarse algo alternativo (ATT).
- Efecto Hawthorne. Es importante que el diseño experimental evite que los dos grupos (tratamiento y control) no se comporten de manera diferente por el hecho de pertenecer a estos grupos, o los resultados podrían sesgarse.

Validez externa.

No es necesaria para la validez de los resultados, pero es lo que garantiza que estos son generalizables a la población. Si por ejemplo uno utiliza una muestra sesgada, los resultados pueden no ser generalizables al resto de la población. Por otro lado, si nuestro tratamiento ofrece una ventaja comparativa al grupo de tratamiento frente al de control, es posible que ofrecer el tratamiento al conjunto poblacional no de lugar a efecto. Por ejemplo, uno podría observar que ofrecer formación a desempleados da lugar a efectos en el empleo, pero solo porque relativamente ahora tienen una ventaja sobre los no tratados. Si se extendiera el tratamiento, volverían a estar todos en las mismas condiciones.

Sin embargo, debido a que son costosos y que no siempre es ético realizar estos experimentos (por ejemplo no sería ético aleatorizar ayudas a la pobreza), los experimentos aleatorizados no siempre se pueden realizar.

3.2. Métodos Cuasi-Experimentales:

El principal problema de los métodos experimentales es que no siempre es posible llevarlos a cabo (por imposibilidad práctica o por cuestiones éticas), lo que lleva, en muchos casos de EPP, a contar con datos observacionales, donde existen diferencias no

observables (sesgo por variables omitidas) entre el grupo de control y el grupo tratado, que impiden que las estimaciones obtenidas sean consistentes. Los métodos cuasi-experimentales permiten manejar los sesgos de selección, incluso cuando estos sesgos se deben a diferencias no observables entre el grupo tratado y el grupo de control. A continuación, describimos tres de las principales técnicas estadísticas dentro de este grupo:

A. Regresión discontinua.

Es uno de los métodos cuasiexperimentales más utilizados y eficaces para la identificación, estimación e inferencia de los efectos de un tratamiento, cuando se dan las condiciones adecuadas para su uso. La idea es simular, con datos observacionales, las condiciones de un experimento. En este caso, se utiliza el umbral por el cual se asigna un tratamiento (por ejemplo, una política para sólo mayores de 59 años), y se utilizan a aquellos ambos lados del umbral pero muy cerca como grupos de tratamiento y control, suponiendo que son grupos muy similares y que la única diferencia entre ellos es la asignación. En este ejemplo, podría ser personas de 59 años en el grupo de control y personas de 60 en el grupo de tratamiento. Lo normal sería que estos grupos fueran muy similares y la única diferencia entre ellos fuera que el punto de corte arbitrario de la política designa como tratados a unos y no a otros.

Mediante la comparación de las observaciones que se extienden estrechamente a ambos lados del umbral, es posible estimar el efecto local del tratamiento promedio en entornos en los que la aleatorización es inviable. Existen dos tipos esenciales de RD en función del cambio que se produce en el umbral: RD nítida (cambio brusco en el umbral), y RD difusa.

Aun pudiendo estimarse tanto de forma paramétrica como con métodos no paramétricos, la forma más simple de estimar estos modelos es a través de una regresión del siguiente tipo restringida a observaciones cuyo valor en la variable de asignación (o móvil) esté comprendido dentro de un determinado rango alrededor del umbral, por lo que es la variable móvil la que asigna (o no) el tratamiento:

$$Y_a = b + b_1 T_a + b_2 \text{Variable asignación}_a + e_a.$$

$\rightarrow \text{edad}$
 $\hookrightarrow 1 \} \text{edad} > 59$

En esta regresión, al incluir como regresor la variable de asignación, el efecto del tratamiento, b_1 , se estaría estimando de forma local; es decir, justo en el umbral que determina la pertenencia al grupo de tratamiento. De esta manera, el estado del tratamiento es una función discontinua de la variable móvil (ya que no cambia hasta alcanzar el umbral, por cerca que esté). Si bien la estimación por MCO es muy sencilla, la forma más habitual de estimar un modelo de regresión discontinua es de forma no paramétrica; y los resultados se suelen representar gráficamente.

Para que la inferencia obtenida a través de un diseño de regresión discontinua sea válida es necesario mostrar que se cumplen una serie de condiciones (Lee y Lemieux, 2010; Abadie y Cattaneo, 2018), como son la ausencia de manipulación en la asignación a un grupo, la ausencia de diferencias en otras variables distintas a la variable objetivo en el entorno cercano al umbral, y la consistencia de los resultados tras la realización del test de «placebo».

B. Diferencias en diferencias.

La metodología de diferencias en diferencias (DiD) es una de las más usadas en la actualidad en la investigación académica económica. Chaisemartin y D'haultfoeuille (2020), por ejemplo, mencionan que 26 de los 100 papers más citados en entre 2015 y 2019 en AER utilizan esta metodología.

El método de diferencias en diferencias nació como una metodología que comparaba la progresión de un grupo de tratamiento y uno de control en dos periodos diferentes. La comparación de las progresiones y no de los niveles post tratamiento da lugar a tener en cuenta las posibles diferencias de base de los grupos de control y tratamiento. El estimador DiD original, es decir, con sólo dos grupos, dos periodos y un tratamiento binario, es equivalente al coeficiente de la interacción entre las variables binarias de grupo (1 si tratamiento) y post (1 si post-tratamiento) obtenido en una regresión con efectos fijos de grupo y tiempo.

No obstante, la metodología ha evolucionado tanto que ahora es más un marco teórico que una metodología única, existiendo diseños complejos con diferentes grupos de tratamiento, tratamiento continuo, tratamiento escalonado, tratamiento intermitente, modelos no lineales... Esto ha dado lugar a que las regresiones TWFE ya no sean las únicas utilizadas para estimar el parámetro de diferencias en diferencias, existiendo otros desarrollados por Borusyak y Jaravel, de Chaisemartin y D'haultfoeuille, Callaway y Sant'anna, Wooldridge... que se adaptan a estos modelos complejos.

En el DiD moderno, se utilizan varios periodos de tiempo, lo que ayuda a la visualización (event-studies frente a estimadores DiD agregadores), pero también a asegurar que los grupos son comparables testando la suposición de tendencias paralelas.

Las tendencias paralelas tratan de mostrar que los grupos de tratamiento y control evolucionaban de manera similar antes del tratamiento. Si esto se puede asegurar con confianza, podríamos suponer que si la evolución cambia tras el tratamiento es debido al mismo. Es importante destacar aquí que las tendencias paralelas no controlan que ambos grupos fueran semejantes en cuanto a nivel de la variable de interés antes del tratamiento, sino que tuvieran una evolución similar, una suposición más laxa en realidad. Para encontrar un grupo de control que evolucione a la par que el de tratamiento, a menudo se utilizan técnicas como Propensity Score Matching o Synthetic Control que permite encontrar grupos de control similares a los de tratamiento dado un vector de variables.

Si bien las tendencias paralelas suponen quizá el supuesto más conocida sobre la que se sostiene la metodología de diferencias en diferencias, también debe cumplirse el supuesto de no contaminación, que dictamina que el grupo de control no debe haber sido afectado por el tratamiento.

C. Variables instrumentales.

Las Instrumental Variables se utilizan para estimar efectos causales cuando una variable explicativa es endógena, es decir, cuando está correlacionada con el término de error del modelo. En ese caso, una regresión por Ordinary Least Squares produce estimadores sesgados e inconsistentes. La endogeneidad puede surgir por diversas razones, como variables omitidas, simultaneidad o errores de medida.

La idea de las variables instrumentales es encontrar una variable Z que genere variación exógena en la variable endógena X . Para que un instrumento sea válido debe cumplir dos condiciones. Primero, **relevancia**, es decir, debe estar correlacionado con la variable explicativa ($Cov(Z, X) \neq 0$). Segundo, debe cumplir la **restricción de exclusión**, es decir, no debe afectar directamente a la variable dependiente ni estar correlacionado con el término de error del modelo ($Cov(Z, u) = 0$). Bajo estas condiciones, el instrumento permite aislar la parte de la variación de X que es exógena.

En la práctica, la estimación suele realizarse mediante **Two-Stage Least Squares**. En la primera etapa se estima una regresión de la variable endógena sobre los instrumentos:

$$X = \pi Z + v$$

lo que permite obtener el valor predicho $\hat{X}$, que representa la componente de X explicada por el instrumento. En la segunda etapa se estima la regresión

$$Y = \beta \hat{X} + \varepsilon$$

Como $\hat{X}$ depende únicamente del instrumento, y este es exógeno por hipótesis, el coeficiente estimado captura el efecto causal de la variación exógena de X sobre Y . Este procedimiento también puede interpretarse dentro del marco del **Generalized Method of Moments**, donde el parámetro se identifica imponiendo la condición de momento $E[Zu] = 0$.

Encontramos un ejemplo en Andersen et al. (2011), que estima los efectos del acceso a internet en la corrupción. Aquí, una regresión simple podría estar sesgada porque ambos fenómenos podrían estar influidos por factores no observados. Por tanto, los autores utilizan como variable instrumental el número de rayos que caen por zona, que afecta a las instalaciones de red, pero no afecta directamente a la corrupción.

Otro ejemplo muy común de variables instrumentales son los instrumentos shift-share o instrumentos de Bartik, utilizados por ejemplo por Autor et al. (2013) para estudiar el efecto de la competencia de importaciones chinas sobre el empleo local en Estados Unidos.